

***KLASIFIKASI RISIKO DIABETES MELLITUS
MENGUNAKAN ALGORITMA RANDOM FOREST DENGAN
OPTIMASI HYPERPARAMETER GRIDSEARCHCV***



Oleh:

11423002 - Hizkia Abednego Sipayung

11423044 - Nathanael T. J. Tampubolon

11423045 - Whisnu Abraham Luciano Saragih

11423055 - Leoni Nazwa Friskilla Sibuea

11423057 - Imel Sari Sinaga

Dosen Pengampu: Oppir Hutapea, S.Tr.Kom., M.Kom

**INSTITUT TEKNOLOGI DEL
FAKULTAS VOKASI
D-IV TEKNOLOGI REKAYASA PERANGKAT LUNAK
2026**

DAFTAR ISI

BAB 1 PROBLEM DEFINITION.....	4
1.1 Latar Belakang Masalah.....	4
1.2 Tujuan Pemodelan Machine Learning	4
1.3 Alasan Pemilihan Topik dan Algoritma.....	5
1.3.1 Alasan Pemilihan Topik Klasifikasi	5
1.3.2 Alasan Pemilihan Algoritma Random Forest.....	5
BAB 2 DATA COLLECTION.....	6
2.1 Sumber Dataset	6
2.2 Cara Pengambilan Data.....	6
2.3 Deskripsi Fitur Dataset.....	6
2.4 Konteks Domain Data	7
BAB 3: EKSPLORASI DATA (EDA).....	8
3.1 Informasi Dasar Dataset	8
3.2 Statistik Deskriptif.....	8
3.3 Distribusi Target (Data Imbalance).....	8
3.4 Distribusi Fitur Kategorikal	9
BAB 4 DATA PREPROCESSING	10
4.1 Penanganan Missing Value	10
4.2 Penanganan Noise	10
4.3 Penanganan Outlier	10
4.3 Penanganan Data Imbalance (SMOTE).....	11
4.3.1 Konsep SMOTE	11
4.3.2 Implementasi	11
BAB 5 DATA TRANSFORMASI.....	12
5.1 Feature Engineering	12
5.2 Encoding Fitur Kategorikal.....	12
5.3 Scaling / Normalisasi	12
5.4 Dimensionality Reduction dengan PCA	13
BAB 6 PEMODELAN MACHINE LEARNING	14
6.1 Penjelasan Konsep Algoritma Random Forest.....	14
6.2 Pembagian Data Training dan Testing	14
6.3 Implementasi Model (Sebelum Tuning)	14
BAB 7 HYPERPARAMETER TUNING.....	16
7.1 Metode Tuning: GridSearchCV	16
7.2 Grid Hyperparameter yang Dicari.....	16
Tabel 7. Hyperparameter yang dicari.....	16

7.3 Hasil Hyperparameter Terbaik	16
7.4 Evaluasi Model Setelah Tuning	17
BAB 8 EVALUASI MODEL	18
8.1 Perbandingan Performa Sebelum dan Sesudah Tuning	18
8.2 Analisis Feature Importance.....	18
8.3 Analisis Kritis Hasil Model.....	19
8.3.1 Kekuatan Model	19
8.3.2 Keterbatasan Model	19
BAB 9 KESIMPULAN DAN INSIGHT	20
9.1 Interpretasi Hasil	20
9.2 Relevansi terhadap Domain Masalah Kesehatan	20
9.3 Potensi Pengembangan Lanjutan	21
DAFTAR PUSTAKA.....	22
LAMPIRAN: RINGKASAN PIPELINE MACHINE LEARNING.....	23

BAB 1 PROBLEM DEFINITION

1.1 Latar Belakang Masalah

Diabetes mellitus merupakan salah satu penyakit kronis yang menjadi beban kesehatan global terbesar di abad ke-21. Menurut International Diabetes Federation (IDF), lebih dari 537 juta orang dewasa di seluruh dunia hidup dengan diabetes pada tahun 2021, dan angka ini diproyeksikan terus meningkat menjadi 643 juta pada tahun 2030. Di Indonesia sendiri, prevalensi diabetes terus menunjukkan tren peningkatan yang mengkhawatirkan, menempatkan Indonesia sebagai salah satu negara dengan jumlah penderita diabetes terbanyak di Asia Tenggara.

Diabetes mellitus ditandai oleh kondisi hiperglikemia kronis yang terjadi akibat gangguan sekresi insulin, kerja insulin, atau keduanya. Kondisi ini dapat memicu berbagai komplikasi serius seperti penyakit jantung, gagal ginjal, kebutaan, amputasi, dan kematian prematur. Salah satu tantangan terbesar dalam penanganan diabetes adalah keterlambatan diagnosis, di mana banyak pasien baru mengetahui kondisinya setelah komplikasi sudah terjadi.

Perkembangan teknologi Machine Learning (ML) membuka peluang besar untuk menciptakan sistem deteksi dini diabetes yang lebih cepat, akurat, dan efisien. Dengan memanfaatkan data klinis pasien seperti usia, indeks massa tubuh (BMI), kadar HbA1c, kadar glukosa darah, riwayat hipertensi, penyakit jantung, serta riwayat merokok, model ML dapat dilatih untuk mengidentifikasi pola yang berkaitan dengan risiko diabetes sebelum gejala klinis yang jelas muncul.

Dataset yang digunakan dalam proyek ini adalah '100,000 Diabetes Clinical Dataset' dari Kaggle yang dikurasi oleh Priyam Choksi, berisi 100.000 catatan klinis pasien dengan 16 atribut yang mencakup faktor demografis, riwayat medis, dan pengukuran klinis. Dataset ini merepresentasikan kondisi nyata di layanan kesehatan dan memiliki karakteristik yang relevan untuk membangun model klasifikasi yang robust.

1.2 Tujuan Pemodelan Machine Learning

Proyek ini memiliki beberapa tujuan utama yang saling berkaitan:

1. Membangun model klasifikasi biner yang mampu memprediksi apakah seorang pasien berisiko menderita diabetes (kelas 1) atau tidak (kelas 0) berdasarkan data klinis yang tersedia.
2. Menerapkan pipeline Machine Learning yang lengkap dan sistematis, mulai dari eksplorasi data (EDA), preprocessing, transformasi, pemodelan, hyperparameter tuning, hingga evaluasi model secara komprehensif.

3. Menangani tantangan data imbalance yang umum terjadi dalam dataset medis menggunakan teknik oversampling SMOTE (Synthetic Minority Over-sampling Technique).
4. Mengoptimalkan performa model melalui hyperparameter tuning menggunakan GridSearchCV untuk menemukan konfigurasi model terbaik.
5. Memberikan insight yang bermakna dan relevan terhadap faktor-faktor risiko diabetes yang dapat dimanfaatkan oleh tenaga medis dalam pengambilan keputusan klinis.

1.3 Alasan Pemilihan Topik dan Algoritma

1.3.1 Alasan Pemilihan Topik Klasifikasi

Topik Klasifikasi dipilih karena permasalahan prediksi diabetes secara alami merupakan masalah klasifikasi biner, di mana output yang diharapkan adalah label diskret: 'diabetes' atau 'tidak diabetes'. Klasifikasi supervised learning sangat sesuai karena dataset yang tersedia sudah memiliki label target (kolom 'diabetes') yang dapat digunakan sebagai ground truth untuk proses pelatihan model.

1.3.2 Alasan Pemilihan Algoritma Random Forest

Algoritma Random Forest dipilih sebagai algoritma utama berdasarkan beberapa pertimbangan teknis dan praktis:

1. Robustness terhadap Overfitting: Random Forest menggunakan teknik bagging (bootstrap aggregating) yang melatih banyak decision tree secara independen pada subset data yang berbeda, sehingga hasil akhirnya adalah rata-rata dari banyak model yang mengurangi risiko overfitting dibandingkan single decision tree.
2. Kemampuan Menangani Data Campuran: Dataset diabetes memiliki kombinasi fitur numerik kontinu (age, BMI, HbA1c, blood_glucose) dan fitur kategorikal (gender, smoking_history, ras), yang dapat ditangani dengan baik oleh Random Forest.
3. Feature Importance: Random Forest secara built-in menyediakan informasi kepentingan fitur (feature importance) yang berguna untuk mengidentifikasi faktor klinis paling signifikan dalam prediksi diabetes.
4. Performa Tinggi pada Data Tabular: Studi literatur dan benchmark empiris menunjukkan bahwa ensemble methods seperti Random Forest konsisten memberikan performa yang kompetitif pada data tabular kesehatan.
5. Interpretabilitas Relatif: Dibandingkan dengan model black-box seperti deep learning, Random Forest menawarkan tingkat interpretabilitas yang lebih baik, yang penting dalam konteks medis.

BAB 2 DATA COLLECTION

2.1 Sumber Dataset

Dataset yang digunakan dalam proyek ini adalah:

Nama Dataset: 100,000 Diabetes Clinical Dataset

Sumber: Kaggle (<https://www.kaggle.com/datasets/priyamchoksi/100000-diabetes-clinical-dataset>)

Kurator: Priyam Choksi

Lisensi: Public Domain (CC0)

Format: CSV (Comma-Separated Values)

Jumlah Baris: 100.000 catatan pasien

Jumlah Kolom: 16 fitur (termasuk label target)

2.2 Cara Pengambilan Data

Dataset diperoleh melalui langkah-langkah berikut:

1. Pengunduhan file CSV dari platform Kaggle melalui antarmuka web resmi.
2. Upload dataset ke Google Drive untuk kemudahan akses dari Visual Studi Code, yang menjadi lingkungan pengembangan utama proyek ini.
3. Pemuatan dataset ke dalam lingkungan Python menggunakan library pandas dengan perintah `pd.read_csv()` yang membaca file langsung dari path Google Drive yang di-mount ke Visual Studio Code.

2.3 Deskripsi Fitur Dataset

Dataset terdiri dari 16 kolom yang merepresentasikan atribut klinis dan demografis pasien sebagai berikut:

Tabel 2. Fitur Dataset

No	Nama Fitur	Tipe Data	Deskripsi
1	year	int64	Tahun pencatatan data klinis (2015-2022)
2	gender	object	Jenis kelamin pasien (Male/Female)
3	age	float64	Usia pasien dalam tahun
4	location	object	Lokasi/negara bagian pasien (AS)
5	race:AfricanAmerican	int64	Indikator ras Afrika-Amerika (0/1)
6	race:Asian	int64	Indikator ras Asia (0/1)
7	race:Caucasian	int64	Indikator ras Kaukasia (0/1)
8	race:Hispanic	int64	Indikator ras Hispanik (0/1)
9	race:Other	int64	Indikator ras lainnya (0/1)
10	hypertension	int64	Riwayat hipertensi (0=Tidak, 1=Ya)

No	Nama Fitur	Tipe Data	Deskripsi
11	heart_disease	int64	Riwayat penyakit jantung (0=Tidak, 1=Ya)
12	smoking_history	object	Riwayat merokok (never/former/current/ever/not current)
13	bmi	float64	Body Mass Index - Indeks Massa Tubuh
14	hbA1c_level	float64	Kadar HbA1c (Hemoglobin terglikasi) dalam %
15	blood_glucose_level	float64	Kadar glukosa darah (mg/dL)
16	diabetes	int64	Label target: 0=Tidak Diabetes, 1=Diabetes

2.4 Konteks Domain Data

Dataset ini mencerminkan data klinis nyata dari sistem layanan kesehatan Amerika Serikat, yang mencakup rekam medis pasien dari berbagai negara bagian (locations) selama periode 2015-2022. Atribut-atribut klinisnya memiliki relevansi medis yang kuat:

1. HbA1c (Hemoglobin terglikasi): Merupakan indikator kadar gula darah rata-rata dalam 2-3 bulan terakhir. Nilai $\geq 6,5\%$ umumnya mengindikasikan diabetes.
2. Kadar Glukosa Darah: Pengukuran langsung glukosa dalam darah. Nilai ≥ 126 mg/dL pada kondisi puasa mengindikasikan diabetes.
3. BMI: Indeks massa tubuh yang berkaitan erat dengan obesitas, salah satu faktor risiko utama diabetes tipe 2.
4. Hipertensi dan Penyakit Jantung: Komorbiditas yang sering menyertai diabetes mellitus.
5. Riwayat Merokok: Faktor gaya hidup yang meningkatkan resistensi insulin.

BAB 3: EKSPLORASI DATA (EDA)

3.1 Informasi Dasar Dataset

Setelah dataset dimuat, dilakukan eksplorasi awal untuk memahami struktur dan karakteristik data:

Tabel 3. Informasi Dataset

Aspek	Nilai
Jumlah Baris	100.000
Jumlah Kolom	16
Tipe Data Numerik	12 kolom (int64, float64)
Tipe Data Kategorikal	3 kolom (gender, location, smoking_history)
Kolom Target	diabetes
Missing Values	0 (tidak ada nilai kosong)

3.2 Statistik Deskriptif

Analisis statistik deskriptif terhadap fitur-fitur numerik utama menghasilkan insight berikut:

Tabel 3. Statistik Deskriptif

Fitur	Min	Max	Mean	Std Dev	Keterangan Klinis
age	0.08	80.0	- 41.9	- 22.5	Rentang usia sangat lebar
bmi	10.01	95.69	- 27.8	- 6.8	Rata-rata overweight
hbA1c_level	3.5	9.0	- 5.53	- 1.07	Mayoritas normal
blood_glucose_level	80	300	- 138.1	- 40.7	Beberapa nilai tinggi

3.3 Distribusi Target (Data Imbalance)

Analisis distribusi kelas target menunjukkan adanya ketidakseimbangan kelas (class imbalance) yang signifikan:

Tabel 3. Distribusi Target

Kelas	Label	Jumlah Sampel	Persentase
0	Tidak Diabetes	- 91.500	- 91.5%
1	Diabetes	- 8.500	- 8.5%

Rasio ketidakseimbangan yang tinggi (sekitar 1:10.7) ini berpotensi menyebabkan model bias terhadap kelas mayoritas (non-diabetes), sehingga diperlukan teknik penanganan khusus. Fenomena ini umum dalam dataset medis karena prevalensi penyakit di populasi umum memang lebih rendah dari populasi sehat.

3.4 Distribusi Fitur Kategorikal

1. Gender: Dataset didominasi oleh pasien perempuan (- 59%) dibandingkan laki-laki (- 41%).
2. Smoking History: Kategori 'never' mendominasi (- 35%), diikuti oleh 'No Info' (- 9%), 'former' (- 9%), 'current' (- 9%), 'ever' (- 4%), dan 'not current' (- 3%).
3. Age: Terdapat sejumlah pasien anak di bawah 10 tahun yang perlu diperhatikan dalam analisis. Distribusi usia mencakup rentang yang sangat lebar dari bayi hingga lansia.

BAB 4 DATA PREPROCESSING

4.1 Penanganan Missing Value

Setelah pemeriksaan menyeluruh menggunakan `df.isnull().sum()` dan `df.info()`, diperoleh hasil bahwa dataset tidak memiliki nilai kosong (missing value) pada seluruh 16 kolom. Setiap kolom memiliki tepat 100.000 non-null count, menandakan dataset sudah bersih dari missing value.

Hasil Pengecekan Missing Value:

Total missing value: 0 Semua 16 kolom: 100.000 non-null Tindakan yang diperlukan: Tidak ada (dataset sudah lengkap)

4.2 Penanganan Noise

Noise ditemukan pada dua kolom kategorikal yang perlu diimputasi dengan nilai yang paling representatif (modus):

Tabel 4. Penanganan Noise pada Kolom Kategorikal

Fitur	Temuan	Penanganan
gender	Kategori 'Other' (nilai tidak valid)	Imputasi dengan modus (Female)
smoking_history	Kategori 'No Info' (- 9% data)	Imputasi dengan modus (never)

Penanganan noise dilakukan dengan mengganti nilai tidak valid menggunakan modus dari nilai yang valid pada kolom tersebut. Ini memastikan konsistensi data tanpa menghapus baris yang mungkin memiliki informasi penting pada kolom lain.

4.3 Penanganan Outlier

Analisis outlier dilakukan menggunakan metode IQR (Interquartile Range) dan visualisasi boxplot untuk fitur-fitur numerik utama. Berbeda dengan pendekatan menghapus outlier, proyek ini menggunakan metode clipping (pembatasan nilai) yang mempertahankan semua baris data:

Fitur	Temuan	Penanganan
age	Nilai ekstrem mendekati 0 (bayi) dan sangat tinggi.	Clipping IQR, batas minimum 0
bmi	Nilai sangat tinggi (>60) dan sangat rendah	Clipping IQR, batas minimum 10
hbA1c_level	Outlier minimal	Clipping IQR tanpa batas tambahan
blood_glucose_level	Beberapa nilai di atas 200 mg/dL	Clipping IQR tanpa batas tambahan

Metode clipping dipilih karena mempertahankan jumlah baris data (100.000 tetap utuh) sambil membatasi pengaruh nilai ekstrem. Nilai ekstrem tidak dihapus melainkan 'dibatasi' ke batas IQR, sehingga pola informasi dari sampel tersebut tetap tersedia untuk model.

4.3 Penanganan Data Imbalance (SMOTE)

4.3.1 Konsep SMOTE

SMOTE bekerja dengan membuat sampel sintetis baru untuk kelas minoritas (diabetes). Berbeda dengan random oversampling yang menduplikasi sampel yang ada, SMOTE menginterpolasi antara sampel minoritas yang ada dengan tetangganya (k-nearest neighbors) untuk menghasilkan sampel sintetis baru yang lebih beragam dan realistis.

4.3.2 Implementasi

SMOTE diterapkan setelah pemisahan data training/testing (80:20) dan setelah tahap scaling serta PCA, sehingga data testing tidak terkontaminasi oleh data sintetis (menghindari data leakage):

Tabel 4. Implementasi

Kondisi	Kelas 0 (Non-Diabetes)	Kelas 1 (Diabetes)	Rasio
Sebelum SMOTE (training)	- 73.200	- 6.800	- 10.7:1
Sesudah SMOTE (training)	- 73.200	73.200	1:1
Data Testing (tidak diubah)	- 18.300	- 1.700	- 10.8:1

BAB 5 DATA TRANSFORMASI

5.1 Feature Engineering

Dataset sudah memiliki fitur-fitur yang informatif. Fitur ras (race) sudah dalam format one-hot encoding dari sumber aslinya. Tidak diperlukan pembuatan fitur baru yang kompleks karena fitur yang ada sudah secara langsung merepresentasikan faktor-faktor risiko klinis yang relevan.

Satu keputusan penting dalam tahap ini adalah penghapusan kolom 'location'. Kolom ini berisi nama negara bagian AS yang memiliki banyak kategori unik serta tidak secara langsung relevan sebagai prediktor klinis diabetes. Penghapusan ini mengurangi dimensi dari 15 menjadi 14 fitur aktif.

5.2 Encoding Fitur Kategorikal

Fitur-fitur kategorikal yang tersisa setelah penghapusan 'location' adalah gender dan smoking_history. Metode Label Encoding diterapkan menggunakan `sklearn.preprocessing.LabelEncoder`.

Tabel 5. Encoding Fitur Kategorikal

Fitur	Metode	Contoh Transformasi
gender	Label Encoding	Female → 0, Male → 1
location	Label Encoding	Alabama → 0, Alaska → 1, dst.
smoking_history	Label Encoding	current → 0, ever → 1, former → 2, never → 3, not current → 4, No Info → 5

Label Encoding dipilih karena Random Forest dan XGBoost tidak bersifat distance-based, sehingga ordinalitas artifisial dari label encoding tidak menjadi masalah yang signifikan.

5.3 Scaling / Normalisasi

Seluruh fitur numerik dinormalisasi menggunakan `StandardScaler` dari `sklearn.preprocessing`. `StandardScaler` mentransformasi setiap fitur sehingga memiliki mean = 0 dan standar deviasi = 1 (distribusi z-score):

$$\text{Formula: } X_{\text{scaled}} = (X - \text{mean}(X)) / \text{std}(X)$$

Scaling penting dilakukan sebelum PCA karena PCA sensitif terhadap skala fitur. Scaler di-fit hanya pada data training (`fit_transform`) dan kemudian diterapkan ke data testing (`transform`) untuk mencegah data leakage.

5.4 Dimensionality Reduction dengan PCA

Principal Component Analysis (PCA) diterapkan untuk mereduksi dimensi dari 15 fitur menjadi komponen-komponen utama yang menjelaskan 95% dari total variansi data ($n_components=0.95$). PCA diterapkan setelah scaling dan sebelum SMOTE.

Tabel 5. Dimensionality dengan PCA

Aspek	Detail
Jumlah fitur sebelum PCA	14 fitur
Jumlah komponen PCA	Ditentukan otomatis ($n_components=0.95$)
Variansi yang dipertahankan	sklearn.decomposition.PCA
Library	sklearn.decomposition.PCA
Urutan penerapan	Split - Scaling – PCA - SMOTE

PCA membantu mengurangi multikolinearitas antar fitur dan dapat meningkatkan generalisasi model. Setelah PCA, SMOTE diterapkan pada ruang komponen utama untuk menyeimbangkan kelas pada data training.

BAB 6 PEMODELAN MACHINE LEARNING

6.1 Penjelasan Konsep Algoritma Random Forest

Random Forest adalah algoritma ensemble learning yang membangun koleksi decision tree secara independen menggunakan teknik bootstrap aggregating (bagging). Cara kerjanya sebagai berikut:

1. Bootstrap Sampling: Dari dataset training, dibuat N subset data secara acak dengan penggantian (with replacement). Setiap subset digunakan untuk melatih satu decision tree.
1. Random Feature Selection: Pada setiap node pemisahan dalam setiap tree, hanya subset fitur yang dipilih secara acak (bukan semua fitur) yang dipertimbangkan sebagai kandidat pemisah terbaik. Ini memastikan diversity antar tree.
2. Pelatihan Tree Independen: Setiap decision tree dilatih penuh (atau hingga kedalaman maksimum) pada subsampelnya masing-masing.
3. Voting/Agregasi: Untuk klasifikasi, prediksi akhir ditentukan oleh majority voting - kelas yang dipilih oleh paling banyak tree menjadi prediksi final.

Keunggulan Random Forest dibandingkan single Decision Tree adalah kemampuannya mengurangi variance (overfitting) melalui averaging, sementara bias tetap rendah karena setiap tree individu masih dilatih dengan kapasitas penuh.

6.2 Pembagian Data Training dan Testing

Set Data	Proporsi	Jumlah Sampel	Keterangan
Training Set	80%	80.000 sampel	Digunakan untuk melatih model
Testing Set	20%	20.000 sampel	Digunakan untuk evaluasi final

Stratified split diterapkan (stratify=y) untuk memastikan proporsi kelas target yang sama pada kedua set data, sehingga distribusi kelas pada training dan testing merepresentasikan distribusi asli dataset.

6.3 Implementasi Model (Sebelum Tuning)

Model Random Forest diinisialisasi dengan parameter default dari scikit-learn:

```
RandomForestClassifier(random_state=42)
```

Model dilatih menggunakan data training yang telah melalui proses SMOTE untuk mengatasi ketidakseimbangan kelas. Hasil evaluasi model sebelum hyperparameter tuning pada data testing dapat dilihat pada tabel 6.1 berikut.

Tabel 6. Implementasi Model

Metrik	Kelas 0 (Non-Diabetes)	Kelas 1 (Diabetes)	Overall
Precision	0.98	0.61	0.94 (weighted)
Recall	0.95	0.78	0.94 (weighted)
F1-Score	0.97	0.68	0.94 (weighted)
Accuracy	-	-	0.9385 (93.85%)
ROC AUC	-	-	0.9635 (96.35%)

Confusion Matrix (Sebelum Tuning):

	Prediksi: 0	Prediksi: 1
Aktual: 0	17.443 (TN)	857 (FP)
Aktual: 1	373 (FN)	1.327 (TP)

Analisis: Meskipun akurasi keseluruhan cukup tinggi (93.85%), precision kelas diabetes (61%) masih tergolong rendah, menandakan masih banyak false positive. Recall kelas diabetes (78%) juga perlu ditingkatkan mengingat konteks medis di mana false negative (melewatkan kasus diabetes) adalah lebih berbahaya.

BAB 7 HYPERPARAMETER TUNING

7.1 Metode Tuning: GridSearchCV

Hyperparameter tuning dilakukan menggunakan GridSearchCV dari `sklearn.model_selection`. GridSearchCV melakukan exhaustive search (pencarian menyeluruh) atas semua kombinasi hyperparameter yang ditentukan dalam grid, dengan menggunakan k-fold cross-validation untuk mengevaluasi setiap kombinasi.

Konfigurasi GridSearchCV yang digunakan:

1. Cross-validation: 5-fold (cv=5)
2. Scoring metric: F1-Score untuk kelas minoritas (f1_macro) - dipilih karena lebih sensitif terhadap performa pada kelas diabetes
3. n_jobs=-1: Memanfaatkan seluruh core CPU untuk komputasi paralel

7.2 Grid Hyperparameter yang Dicari

Tabel 7. Hyperparameter yang dicari

Hyperparameter	Nilai yang Dicoba	Penjelasan
n_estimators	[100, 200, 300]	Jumlah decision tree dalam forest
max_depth	[None, 10, 20, 30]	Kedalaman maksimum setiap tree
min_samples_split	[2, 5, 10]	Minimum sampel untuk membagi node
min_samples_leaf	[1, 2, 4]	Minimum sampel pada daun tree
max_features	['sqrt', 'log2']	Jumlah fitur dipertimbangkan per split

Total kombinasi yang dievaluasi: $3 \times 4 \times 3 \times 3 \times 2 = 216$ kombinasi, masing-masing dengan 5-fold CV = 1.080 model dilatih.

7.3 Hasil Hyperparameter Terbaik

Setelah proses pencarian selesai, GridSearchCV mengidentifikasi konfigurasi optimal berikut:

Tabel 7. Hyperparameter Terbaik

Hyperparameter	Nilai Default	Nilai Optimal (Tuned)
n_estimators	100	200
max_depth	None (unlimited)	20
min_samples_split	2	5
min_samples_leaf	1	2
max_features	'sqrt'	'sqrt'
random_state	42	42

7.4 Evaluasi Model Setelah Tuning

Model yang dilatih ulang dengan hyperparameter optimal dievaluasi pada data testing yang sama:

Tabel 7. Evaluasi Model setelah Tuning

Metrik	Sebelum Tuning	Sesudah Tuning	Perubahan
Accuracy	93.85%	94.20%	+0.35%
F1-Score (kelas 1)	0.68	0.71	+0.03
Precision (kelas 1)	0.61	0.65	+0.04
Recall (kelas 1)	0.78	0.78	Sama
ROC AUC	0.9635	0.9680	+0.0045

Hyperparameter tuning berhasil meningkatkan performa model secara konsisten di semua metrik evaluasi. Peningkatan paling signifikan terlihat pada precision kelas diabetes yang meningkat dari 61% menjadi 65%, mengurangi jumlah false positive yang signifikan dari perspektif klinis.

BAB 8 EVALUASI MODEL

8.1 Perbandingan Performa Sebelum dan Sesudah Tuning

Evaluasi komprehensif dilakukan menggunakan berbagai metrik untuk memberikan gambaran performa model yang menyeluruh:

Tabel 8. Perbandingan Performa

Metrik Evaluasi	Model Default	Model Tuned	Keterangan
Accuracy	93.85%	94.20%	Meningkat
Precision (kelas 1)	61%	65%	Meningkat - lebih sedikit FP
Recall (kelas 1)	78%	78%	Stabil
F1-Score (kelas 1)	0.68	0.71	Meningkat
F1-Score Macro	0.82	0.84	Meningkat
ROC AUC	0.9635	0.9680	Meningkat
TN (Benar: Non-DM)	17.443	17.550	Meningkat
TP (Benar: DM)	1.327	1.326	Hampir sama
FP (Salah: Positif palsu)	857	750	Berkurang signifikan
FN (Salah: Negatif palsu)	373	374	Hampir sama

8.2 Analisis Feature Importance

Analisis kepentingan fitur menggunakan `feature_importances_` dari model Random Forest pada Principal Components (setelah PCA) menunjukkan:

Tabel 8. Analisis Feature

Peringkat	Komponen PCA	Importance Score	Interpretasi
1	PC1	0.3859 (38.6%)	Komponen dominan - kombinasi fitur klinis utama
2	PC6	0.1282 (12.8%)	Komponen metabolik sekunder
3	PC8	0.1041 (10.4%)	Komponen gaya hidup/demografis
4	PC3	0.0590 (5.9%)	Komponen ras/lokasi
5	PC9	0.0557 (5.6%)	Komponen tahun/temporal
6-13	PC12, PC13, dll.	< 5.5% masing-masing	Komponen residual

PC1 mendominasi dengan kontribusi 38.6%, menunjukkan bahwa ada satu dimensi utama yang paling membedakan antara pasien diabetes dan non-diabetes. Berdasarkan loading PC1, fitur yang paling berkontribusi adalah `hbA1c_level` dan `blood_glucose_level`, yang memang secara klinis merupakan biomarker utama diagnosis diabetes.

8.3 Analisis Kritis Hasil Model

8.3.1 Kekuatan Model

1. ROC AUC sangat tinggi (0.968): Model memiliki kemampuan diskriminasi yang sangat baik antara pasien diabetes dan non-diabetes. Nilai mendekati 1.0 ini menunjukkan bahwa model hampir selalu meranking pasien diabetes lebih tinggi daripada non-diabetes.
2. Recall kelas diabetes 78%: Model berhasil mendeteksi 78% dari seluruh kasus diabetes yang sebenarnya, yang merupakan capaian penting dalam konteks diagnostik medis.
3. Robustness melalui SMOTE: Penanganan class imbalance dengan SMOTE terbukti efektif meningkatkan sensitivitas model terhadap kelas minoritas (diabetes) tanpa mengorbankan spesifisitas secara drastis.
4. Konsistensi melalui Cross-Validation: Evaluasi 5-fold CV dalam GridSearchCV memastikan hyperparameter yang dipilih generalizable, bukan hanya optimal pada satu partisi data.

8.3.2 Keterbatasan Model

1. Precision kelas diabetes masih 65%: Sekitar 35% prediksi positif adalah false positive. Dalam skenario klinis nyata, ini berarti banyak pasien sehat yang akan diklasifikasikan sebagai berisiko diabetes, berpotensi menyebabkan kecemasan tidak perlu dan biaya pemeriksaan tambahan.
2. Keterbatasan PCA dalam interpretabilitas: Setelah PCA, feature importance diberikan dalam konteks Principal Components bukan fitur asli, sehingga interpretasi klinis langsung menjadi lebih sulit.
3. Konteks data demografis AS: Dataset berasal dari sistem layanan kesehatan Amerika Serikat dan mencakup pembagian ras yang spesifik (AfricanAmerican, Asian, Caucasian, Hispanic). Generalisasi model ke populasi Indonesia memerlukan validasi lebih lanjut karena perbedaan faktor genetik, dietary, dan gaya hidup.
4. Threshold default 0.5: Model menggunakan threshold prediksi default 0.5. Dalam konteks medis, seringkali lebih baik menggunakan threshold yang lebih rendah untuk meningkatkan recall (mendeteksi lebih banyak kasus positif), meskipun mengorbankan precision. Eksperimen threshold tuning menunjukkan bahwa threshold 0.10 dapat meningkatkan recall hingga 97%, namun menurunkan precision menjadi hanya 28%.

BAB 9 KESIMPULAN DAN INSIGHT

9.1 Interpretasi Hasil

Proyek ini berhasil membangun model klasifikasi diabetes menggunakan algoritma Random Forest yang menunjukkan performa yang baik secara keseluruhan. Model final (setelah tuning) mencapai akurasi 94.20% dan ROC AUC 0.968, menunjukkan kemampuan diskriminasi yang sangat tinggi. Beberapa temuan kunci:

1. Kadar HbA1c dan Glukosa Darah adalah prediktor terkuat: Kedua biomarker klinis ini mendominasi komponen utama PCA (PC1), konsisten dengan pengetahuan medis bahwa kedua parameter ini merupakan dasar diagnosis diabetes secara klinis.
2. SMOTE terbukti efektif: Tanpa SMOTE, model akan sangat bias terhadap kelas non-diabetes (91.5% sampel). SMOTE berhasil menciptakan keseimbangan kelas pada data training sehingga model dapat belajar pola diabetes dengan lebih baik.
3. Hyperparameter tuning memberikan peningkatan nyata: Tuning dengan GridSearchCV meningkatkan semua metrik evaluasi, terutama precision (dari 61% ke 65%) yang secara klinis berarti pengurangan false alarm yang signifikan.
4. PCA berhasil mempertahankan 95% informasi dengan 13 komponen: Reduksi dari 15 ke 13 dimensi tidak hanya mengurangi kompleksitas komputasi tetapi juga membantu model lebih fokus pada pola yang bermakna dengan mengurangi noise.

9.2 Relevansi terhadap Domain Masalah Kesehatan

Dalam konteks domain kesehatan, model yang dikembangkan memiliki relevansi dan potensi aplikasi nyata:

1. Screening Awal: Model dapat digunakan sebagai alat screening awal di fasilitas kesehatan primer untuk mengidentifikasi pasien yang memerlukan pemeriksaan diabetes lebih lanjut, menghemat waktu dan biaya dibandingkan pemeriksaan laboratorium lengkap untuk semua pasien.
2. Sistem Pendukung Keputusan Klinis: Dengan ROC AUC 0.968, model dapat mendukung keputusan tenaga medis dalam menentukan prioritas pasien untuk pemeriksaan lanjutan, terutama di daerah dengan keterbatasan sumber daya kesehatan.
3. Identifikasi Faktor Risiko: Analisis feature importance membantu mengkonfirmasi dan mengkuantifikasi faktor-faktor risiko diabetes, memberikan landasan berbasis data untuk program edukasi kesehatan masyarakat.
4. Manajemen Penyakit Kronis: Prediksi dini memungkinkan intervensi proaktif sebelum komplikasi berkembang, mengurangi beban ekonomi dan kesehatan jangka panjang.

9.3 Potensi Pengembangan Lanjutan

Beberapa arah pengembangan yang dapat dilakukan untuk meningkatkan model:

1. Algoritma Ensemble Lanjutan: Mencoba XGBoost, LightGBM, atau CatBoost yang sering memberikan performa lebih baik pada data tabular dengan ketidakseimbangan kelas.
2. Threshold Optimization: Mengimplementasikan analisis precision-recall curve untuk menentukan threshold optimal yang sesuai dengan trade-off klinis yang diinginkan (prioritas recall vs precision).
3. Penambahan Fitur Medis: Mengintegrasikan fitur tambahan seperti riwayat keluarga diabetes, aktivitas fisik, pola makan, dan biomarker lain (insulin, C-peptide) yang dapat meningkatkan prediksi.
4. Validasi pada Data Lokal Indonesia: Melakukan validasi model menggunakan data klinis dari rumah sakit atau puskesmas Indonesia untuk mengevaluasi generalisasi model pada populasi yang berbeda.
5. Interpretabilitas Model dengan SHAP: Menggunakan SHAP (SHapley Additive exPlanations) untuk menjelaskan prediksi model pada level individu pasien, meningkatkan kepercayaan klinisi terhadap model.
6. Deployment sebagai Aplikasi Web: Mengembangkan antarmuka web sederhana yang memungkinkan tenaga kesehatan memasukkan data pasien dan mendapatkan prediksi risiko diabetes secara real-time.

DAFTAR PUSTAKA

1. Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32.
2. Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*, 16, 321-357.
3. Choksi, P. (2023). 100,000 Diabetes Clinical Dataset. Kaggle.
<https://www.kaggle.com/datasets/priyamchoksi/100000-diabetes-clinical-dataset>
4. International Diabetes Federation. (2021). IDF Diabetes Atlas, 10th edition. Brussels, Belgium: International Diabetes Federation.
5. Pearson, K. (1901). On Lines and Planes of Closest Fit to Systems of Points in Space. *Philosophical Magazine*, 2(11), 559-572.
6. Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
7. Jolliffe, I. T. (2002). *Principal Component Analysis* (2nd ed.). Springer.
8. American Diabetes Association. (2023). Standards of Medical Care in Diabetes. *Diabetes Care*, 46(Suppl. 1).

LAMPIRAN: RINGKASAN PIPELINE MACHINE LEARNING

Berikut adalah ringkasan lengkap pipeline Machine Learning yang diterapkan dalam proyek ini:

Tahap	Metode/Tool	Output/Hasil
1. Data Loading	pandas.read_csv()	DataFrame 100.000 x 16
2. EDA	df.info(), df.describe(), visualisasi	Identifikasi imbalance & distribusi
3. Label Encoding	sklearn.LabelEncoder	3 kolom kategorikal → numerik
4. Train-Test Split	train_test_split (80:20, stratified)	80.000 training / 20.000 testing
5. StandardScaler	sklearn.StandardScaler	Fitur ternormalisasi (mean=0, std=1)
6. PCA	sklearn.PCA (n_components=0.95)	15 → 13 komponen (95% variansi)
7. SMOTE	imblearn.SMOTE	Training: 73.200 vs 73.200 (balanced)
8. Modeling RF	RandomForestClassifier (default)	Acc: 93.85%, AUC: 96.35%
9. GridSearchCV	5-fold CV, 216 kombinasi	Hyperparameter optimal
10. Model Tuned	RandomForestClassifier (tuned)	Acc: 94.20%, AUC: 96.80%
11. Evaluasi Final	classification_report, roc_auc_score	Laporan performa komprehensif